

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
[TÊN KHOA]

[HỌ VÀ TÊN SINH VIÊN]

BÁO CÁO CHUYÊN ĐỀ TỐT NGHIỆP
XÂY DỰNG HỆ THỐNG PHÁT HIỆN SAI LỆCH NGOẠI
QUAN
CỦA SẢN PHẨM ĐỒ TRANG TRÍ XUẤT KHẨU
SỬ DỤNG THỊ GIÁC MÁY TÍNH

Computer Vision-Based Visual Anomaly Detection

CỬ NHÂN/KỸ SƯ NGÀNH [TÊN NGÀNH]

MÃ SỐ SINH VIÊN: [MSSV]

TP. HỒ CHÍ MINH, 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
[TÊN KHOA]

[HỌ VÀ TÊN SINH VIÊN]

BÁO CÁO CHUYÊN ĐỀ TỐT NGHIỆP
XÂY DỰNG HỆ THỐNG PHÁT HIỆN SAI LỆCH NGOẠI
QUAN
CỦA SẢN PHẨM ĐỒ TRANG TRÍ XUẤT KHẨU
SỬ DỤNG THỊ GIÁC MÁY TÍNH

Computer Vision-Based Visual Anomaly Detection

CỬ NHÂN/KỸ SƯ NGÀNH [TÊN NGÀNH]

GIẢNG VIÊN HƯỚNG DẪN
[HỌ TÊN, HỌ TÊN GIẢNG VIÊN]

TP. HỒ CHÍ MINH, 2026

THÔNG TIN HỘI ĐỒNG CHẤM CHUYÊN ĐỀ TỐT NGHIỆP

Hội đồng chấm chuyên đề tốt nghiệp được thành lập theo Quyết định số [SỐ QUYẾT ĐỊNH], ngày [NGÀY/THÁNG/NĂM] của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

STT	Họ và tên	Chức danh trong hội đồng
1	[HỌ TÊN]	Chủ tịch
2	[HỌ TÊN]	Thư ký
3	[HỌ TÊN]	Ủy viên

LỜI CẢM ƠN

Em xin chân thành cảm ơn quý thầy cô Trường Đại học Công nghệ Thông tin đã trang bị nền tảng kiến thức và tạo điều kiện để em thực hiện chuyên đề tốt nghiệp. Em đặc biệt biết ơn giảng viên hướng dẫn đã định hướng phương pháp nghiên cứu, góp ý về thiết kế thí nghiệm và hỗ trợ em kiểm tra các giả định trong quá trình xây dựng hệ thống phát hiện sai lệch ngoại quan. Em cũng cảm ơn đơn vị cung cấp dữ liệu và những người đã hỗ trợ thu thập, rà soát hình ảnh sản phẩm. Do giới hạn về thời gian, quy mô dữ liệu và kinh nghiệm thực hiện, báo cáo khó tránh khỏi thiếu sót; em mong nhận được góp ý để tiếp tục hoàn thiện nghiên cứu.

TP. Hồ Chí Minh, tháng 9 năm 2026

Sinh viên thực hiện

[HỌ VÀ TÊN]

MỤC LỤC

TÓM TẮT	1
CHƯƠNG 1. MỞ ĐẦU.....	2
1.1. Lý do chọn đề tài	2
1.2. Mục tiêu nghiên cứu.....	2
1.3. Đối tượng và phạm vi nghiên cứu	3
1.4. Phương pháp nghiên cứu.....	3
1.5. Đóng góp của chuyên đề	3
1.6. Bố cục báo cáo.....	4
CHƯƠNG 2. TỔNG QUAN NGHIÊN CỨU	5
2.1. Phát hiện bất thường dựa trên ngân hàng bộ nhớ và đặc trưng nhúng.....	5
2.2. Phương pháp tái cấu trúc và huấn luyện khuyết tật tổng hợp	5
2.3. Đường cơ sở thống kê cổ điển.....	6
2.4. Bộ dữ liệu chuẩn và khác biệt của bối cảnh nghiên cứu	6
CHƯƠNG 3. DỮ LIỆU VÀ PHÁT BIỂU BÀI TOÁN.....	8
3.1. Tập dữ liệu.....	8
3.2. Sự thay đổi vị trí và kích thước đối tượng.....	8
3.3. Quy mô khuyết tật	9
3.4. Mất cân bằng dữ liệu	9
3.5. Phát biểu bài toán	10
CHƯƠNG 4. PHƯƠNG PHÁP VÀ THIẾT KẾ HỆ THỐNG	11
4.1. Tổng quan quy trình OC-MAR	11
4.2. Tiền xử lý ảnh.....	11
4.3. Loại bỏ nền và tạo mặt nạ đối tượng	12
4.4. Mô hình PatchCore.....	13

4.5. Đầu vào và tổng hợp đa tỷ lệ.....	14
4.6. Lọc giới hạn đối tượng và tinh chỉnh vùng	14
4.7. Phân ngưỡng.....	15
CHƯƠNG 5. THIẾT LẬP THỰC NGHIỆM	16
5.1. Quy trình phân chia dữ liệu	16
5.2. Chỉ số đánh giá	16
5.3. Tỷ lệ coreset	16
5.4. Các cấu hình so sánh	17
5.5. Đường cơ sở thống kê cổ điển.....	17
5.6. Phương pháp thay thế	18
CHƯƠNG 6. KẾT QUẢ VÀ ĐÁNH GIÁ.....	19
6.1. Hiệu suất phát hiện cơ sở	19
6.2. So sánh với đường cơ sở thống kê	19
6.3. Ảnh hưởng của bước loại bỏ nền	20
6.4. Sai lệch mặt nạ đối với vật thể tối	20
6.5. Cấu hình cuối cùng và độ phân giải đầu vào.....	22
6.6. Độ ổn định theo hạt giống ngẫu nhiên	23
6.7. Đánh giá tổng hợp đa tỷ lệ	24
6.8. Ngưỡng thích ứng theo từng mẫu.....	27
6.9. Đánh giá định tính khả năng định vị	28
6.10. Đánh giá định lượng trên tập chú thích thủ công	30
CHƯƠNG 7. THẢO LUẬN	34
7.1. Ý nghĩa của kết quả	34
7.2. Ảnh hưởng của tiền xử lý và hậu xử lý	34
7.3. Lựa chọn giữa mô hình không huấn luyện và mô hình có huấn luyện ...	35

7.4. Khả năng ứng dụng và giới hạn	35
CHƯƠNG 8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	37
8.1. Kết luận	37
8.2. Hướng phát triển.....	37
TÀI LIỆU THAM KHẢO	39
PHỤ LỤC A. THỬ NGHIỆM SUPERSIMPLENET	40
A.1. Thiết lập.....	40
A.2. Hiệu chỉnh theo triển khai tham chiếu.....	40
A.3. Phân tích kết quả không hội tụ	41

DANH MỤC HÌNH

Hình 2.1. Ví dụ ảnh bình thường và ảnh lỗi của một số mẫu sản phẩm.	7
Hình 3.1. Phân bố vị trí và kích thước hộp bao đối tượng trong dữ liệu.	9
Hình 3.2. Số lượng ảnh bình thường và ảnh lỗi theo từng mẫu sản phẩm.....	10
Hình 4.1. Quy trình OC-MAR gồm chín giai đoạn.....	11
Hình 4.2. So sánh mặt nạ alpha và mặt nạ ngưỡng màu trên vật thể tối.....	13
Hình 4.3. Nguyên lý xây dựng ngân hàng bộ nhớ và suy luận của PatchCore [4].....	14
Hình 6.1. Vật thể tối bị bỏ sót khi tái tạo mặt nạ bằng ngưỡng màu.	22
Hình 6.2. Bản đồ bất thường theo từng tỷ lệ và kết quả tổng hợp.	26
Hình 6.3. Kết quả định vị trên ảnh lỗi: (a) FA-808; (b) FA-1047.....	29
Hình 6.4. Đối chiếu định vị: (a) ảnh bình thường FA-808; (b) các mẫu sản phẩm còn lại.	30
Hình 6.5. Ví dụ đối chiếu vùng dự đoán với mặt nạ chú thích thủ công.	33
Hình A.1. Hàm mất mát huấn luyện SuperSimpleNet trên FA-1047 và FA-808.	42

DANH MỤC BẢNG

Bảng 2.1. So sánh các nhóm phương pháp được xem xét.....	7
Bảng 3.1. Tóm tắt tập dữ liệu nghiên cứu.	10
Bảng 4.1. Chức năng của các giai đoạn OC-MAR.	15
Bảng 5.1. Các cấu hình thực nghiệm chính.....	18
Bảng 6.1. AUROC của Isolation Forest và PatchCore cơ sở.....	19
Bảng 6.2. Sai lệch của mặt nạ ngưỡng màu so với mặt nạ alpha.....	21
Bảng 6.3. AUROC của cấu hình cuối cùng theo từng mẫu sản phẩm.	23
Bảng 6.4. AUROC trung bình và độ lệch chuẩn trên năm hạt giống.....	24

Bảng 6.5. So sánh đơn tỷ lệ và tổng hợp đa tỷ lệ.	25
Bảng 6.6. Hiệu quả ngưỡng thích ứng theo mẫu sản phẩm.	27
Bảng 6.7. Chỉ số định vị trên 192 ảnh được chú thích thủ công.	31

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nội dung
AUROC	Area Under the Receiver Operating Characteristic Curve
CNN	Convolutional Neural Network
FP	False Positive - dương tính giả
GLCM	Gray-Level Co-occurrence Matrix
IoU	Intersection over Union
LBP	Local Binary Pattern
OC-MAR	Object-Constrained Multi-scale Anomaly Recognition
PRO	Per-Region Overlap

TÓM TẮT

Chuyên đề nghiên cứu bài toán phát hiện và định vị sai lệch ngoại quan trên tập dữ liệu công nghiệp thực tế gồm 12 mẫu sản phẩm đồ trang trí xuất khẩu. Mỗi mẫu có 100 ảnh bình thường; ảnh lỗi chỉ được dùng để đánh giá, dao động từ 30 đến 53 ảnh và không có mặt nạ lỗi ở mức pixel. Trong điều kiện dữ liệu khan hiếm này, báo cáo lựa chọn PatchCore - phương pháp phát hiện bất thường dựa trên bộ nhớ, không cần huấn luyện lại bộ trích xuất đặc trưng - làm mô hình chính. Quy trình được tổ chức theo khung OC-MAR gồm tiền xử lý, tạo mặt nạ đối tượng, suy luận PatchCore, giới hạn tiền cảnh, đánh giá đa tỷ lệ, ngưỡng thích ứng và tinh chỉnh vùng.

Cấu hình cuối cùng đạt AUROC trung bình cấp ảnh 0,996, ổn định với độ lệch chuẩn của giá trị trung bình khoảng 0,0019 trên năm hạt giống ngẫu nhiên và cao hơn đường cơ sở thống kê cổ điển 0,898. Phân tích cũng chỉ ra một lỗi quan trọng khi tái tạo mặt nạ bằng ngưỡng màu trên ảnh đã loại bỏ nền: ba mẫu tối nhất bị bỏ sót 78-96% pixel đối tượng, với hệ số tương quan giữa tỷ lệ âm tính giả và độ sáng đối tượng là $r = -0,938$. Việc dùng trực tiếp kênh alpha của mô hình tách nền khắc phục được hạn chế này.

Đối với định vị, ngưỡng thích ứng theo từng mẫu sản phẩm làm giảm 66% diện tích dương tính giả trung bình mà không ảnh hưởng đến AUROC phân loại. Tổng hợp đa tỷ lệ không tạo cải thiện rõ rệt so với độ phân giải 384 x 384, trong khi chi phí suy luận tăng gần ba lần. Trên tập tham chiếu 192 ảnh được chú thích thủ công, IoU trung bình đạt 0,220 và độ chính xác pointing game đạt 0,875, cho thấy hệ thống thường xác định đúng vùng lỗi tổng quát nhưng chưa mô tả chính xác biên lỗi. Kết quả khẳng định PatchCore kết hợp tiền xử lý được kiểm chứng là lựa chọn thực tế cho kiểm tra ngoại quan khi dữ liệu lỗi và nhãn pixel rất hạn chế.

Từ khóa: phát hiện bất thường; PatchCore; thị giác máy tính; kiểm tra ngoại quan; dữ liệu khan hiếm; OC-MAR.

CHƯƠNG 1. MỞ ĐẦU

1.1. Lý do chọn đề tài

Kiểm tra ngoại quan là công đoạn quan trọng đối với sản phẩm đồ trang trí xuất khẩu, nơi sai lệch về màu sắc, chi tiết in hoặc bộ phận bị thiếu có thể làm giảm chất lượng lô hàng. Kiểm tra thủ công phụ thuộc nhiều vào kinh nghiệm, dễ bị ảnh hưởng bởi mệt mỏi và khó duy trì tiêu chuẩn đồng nhất khi số lượng mẫu sản phẩm thay đổi. Trong khi đó, các hệ thống học sâu giám sát thường cần số lượng lớn ảnh lỗi đã gán nhãn, điều không phù hợp với dây chuyền quy mô nhỏ vì lỗi hiếm, hình dạng lỗi khó dự đoán và chi phí chú thích pixel cao.

Bối cảnh thực tế của chuyên đề chỉ cung cấp 100 ảnh bình thường cho mỗi trong 12 mẫu sản phẩm và 30-53 ảnh lỗi để đánh giá. Đối tượng không cố định hoàn toàn về vị trí, tỷ lệ và hướng chụp. Vì vậy, đề tài tập trung vào phát hiện bất thường một lớp: mô hình học biểu diễn từ ảnh bình thường, sau đó nhận biết ảnh và vùng có đặc trưng lệch khỏi phân bố chuẩn.

1.2. Mục tiêu nghiên cứu

- Xây dựng quy trình phát hiện ảnh bình thường và ảnh có sai lệch ngoại quan cho từng mẫu sản phẩm.
- Định vị vùng nghi ngờ lỗi ở mức pixel mà không sử dụng mặt nạ lỗi trong giai đoạn huấn luyện.
- Đánh giá ảnh hưởng của loại bỏ nền, độ phân giải, giới hạn tiền cảnh, đa tỷ lệ và ngưỡng thích ứng.
- So sánh PatchCore với đường cơ sở thống kê cổ điển và ghi nhận kết quả thử nghiệm SuperSimpleNet.
- Xác định các giới hạn thực tế và đề xuất hướng hoàn thiện để có thể triển khai trong sản xuất.

1.3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là ảnh JPEG của 12 mã sản phẩm FA-504, FA-808, FA-838, FA-924, FA-1041, FA-1042, FA-1043, FA-1045, FA-1047, FA-1113, FA-1114 và FA-1120. Nghiên cứu giới hạn ở phát hiện bất thường ngoại quan trên ảnh tĩnh, không thiết kế cơ khí dây chuyền, không đánh giá tốc độ thời gian thực trên thiết bị nhúng và không sử dụng ảnh lỗi để huấn luyện mô hình chính.

1.4. Phương pháp nghiên cứu

Nghiên cứu kết hợp khảo sát tài liệu, phân tích dữ liệu thăm dò, xây dựng mô hình thực nghiệm và so sánh định lượng. PatchCore được triển khai độc lập theo từng mẫu sản phẩm; 80 ảnh bình thường dùng để xây dựng ngân hàng bộ nhớ và 20 ảnh bình thường giữ lại cho hiệu chuẩn. Toàn bộ ảnh lỗi chỉ tham gia đánh giá. Các chỉ số chính gồm AUROC cấp ảnh, IoU, độ phủ vùng và pointing game. Phân tích định tính dùng bản đồ nhiệt và đường biên vùng được giữ lại.

1.5. Đóng góp của chuyên đề

- Hoàn thiện quy trình OC-MAR chín giai đoạn cho dữ liệu công nghiệp khan hiếm, đạt AUROC trung bình 0,996.
- Phát hiện có hệ thống lỗi tạo mặt nạ trên vật thể tối và chứng minh mối liên hệ với độ sáng đối tượng.
- Đánh giá riêng tác động của đa tỷ lệ và ngưỡng thích ứng, tránh quy kết cải thiện khi chưa có bằng chứng.
- Xây dựng tập tham chiếu 192 ảnh chú thích thủ công để bổ sung đánh giá định vị định lượng.
- Báo cáo minh bạch kết quả không hội tụ của SuperSimpleNet trong điều kiện 80 ảnh huấn luyện mỗi mẫu.

1.6. Bố cục báo cáo

Báo cáo gồm tám chương. Sau phần mở đầu, Chương 2 tổng quan các hướng nghiên cứu liên quan; Chương 3 mô tả dữ liệu và phát biểu bài toán; Chương 4 trình bày phương pháp và thiết kế quy trình; Chương 5 nêu thiết lập thực nghiệm; Chương 6 báo cáo kết quả; Chương 7 thảo luận các phát hiện, giới hạn và khả năng triển khai; Chương 8 kết luận và đề xuất hướng phát triển. Tài liệu tham khảo và phụ lục được trình bày ở cuối báo cáo.

CHƯƠNG 2. TỔNG QUAN NGHIÊN CỨU

2.1. Phát hiện bất thường dựa trên ngân hàng bộ nhớ và đặc trưng nhúng

PatchCore [4], bộ dò mà tôi xây dựng dựa trên, thuộc một họ các phương pháp một lớp chấm điểm các điểm bất thường bằng khoảng cách giữa phần nhúng của một mảng thử nghiệm, từ một xương sống được huấn luyện trước trên ImageNet đã được đóng băng, và một ngân hàng bộ nhớ chứa các phần nhúng của mảng hình ảnh bình thường, được lấy mẫu con thành một tập lỗi để dễ xử lý. Họ mô hình này không yêu cầu huấn luyện dựa trên gradient cho chính mạng xương sống, chỉ cần tìm kiếm lân cận gần nhất và lựa chọn tập lỗi, điều này khiến nó tương đối phù hợp với các thiết lập có rất ít ảnh huấn luyện thông thường, chẳng hạn như 80 ảnh mỗi mẫu sản phẩm (sau khi chia tách hiệu chuẩn) được sử dụng xuyên suốt công trình này. Hạn chế chính của nó đối với mục đích của chúng ta

là việc định vị là một sản phẩm phụ gián tiếp của bản đồ khoảng cách lưới và chứ không phải là kết quả phân đoạn được huấn luyện trực tiếp, điều này thúc đẩy quá trình xử lý hậu kỳ hạn chế tiền cảnh được mô tả trong Phần 4. 6 và việc đánh giá định vị chỉ mang tính định tính được thảo luận như một hạn chế trong Phần 5.

2.2. Phương pháp tái cấu trúc và huấn luyện khuyết tật tổng hợp

Một họ khác huấn luyện mạng phân đoạn trực tiếp, sử dụng các khiếm khuyết giả được tạo ra tổng hợp để không cần hình ảnh khiếm khuyết thực sự trong quá trình huấn luyện. DRAEM [5] tái tạo đầu vào bị hỏng tổng hợp và huấn luyện một mạng con phân biệt để phân đoạn vùng bị hỏng so với bản tái tạo. SuperSimpleNet [3], mà tôi đã thử nghiệm như một giải pháp thay thế cho PatchCore trong công việc này, tuân theo một công thức liên quan, các khiếm khuyết giả nhiều Perlin được đưa trực tiếp vào không gian đặc trưng, với một bộ phân biệt nhẹ tạo ra cả phân loại cấp độ hình ảnh và bản đồ phân đoạn cấp độ pixel, và tùy chọn kết hợp hình ảnh khiếm khuyết thực sự khi có sẵn.

Về nguyên tắc, họ mô hình này cung cấp một con đường trực tiếp hơn để phân đoạn sắc nét từng pixel so với bản đồ khoảng cách lân cận gần nhất. Trên thực tế, như đã báo cáo trong Phụ lục A, nỗ lực SuperSimpleNet của tôi đã không hội tụ trên tập dữ liệu này ngay cả sau ba vòng hiệu chỉnh kiến trúc so với triển khai tham chiếu, điều mà tôi tạm thời cho là do sự kết hợp của tập huấn luyện cực kỳ nhỏ cho mỗi mẫu sản phẩm (80 hình ảnh) và có thể là một chi tiết sao chép hàng loạt không được tái tạo của vòng lặp huấn luyện ban đầu, hơn là do lỗi triển khai còn sót lại.

2.3. Đường cơ sở thống kê cổ điển

Việc chấm điểm bất thường bằng thống kê hình ảnh được tạo thủ công và bộ phát hiện ngoại lệ đa năng, chẳng hạn như Isolation Forest [2], có trước các phương pháp dựa trên nhúng sâu ở trên và vẫn là một điểm so sánh phù hợp chính xác vì nó không yêu cầu xương sống được huấn luyện trước và có chi phí huấn luyện thấp. Mục 5. 5 và Mục 6 sử dụng chính xác sự kết hợp này làm cơ sở so sánh với PatchCore, để kiểm tra xem khoảng cách do các tính năng sâu tạo ra có phải là thật hay chỉ là kết quả giả tạo của một phép so sánh yếu kém khác.

2.4. Bộ dữ liệu chuẩn và khác biệt của bối cảnh nghiên cứu

Hầu hết các tài liệu về phát hiện dị thường nêu trên, bao gồm cả các đánh giá PatchCore và DRAEM ban đầu, đều được đánh giá trên MVTEC AD [1], một tập dữ liệu được sử dụng rộng rãi cung cấp độ chính xác pixel trên mặt đất- Các mặt nạ lỗi thực tế và, đối với hầu hết các danh mục, có khoảng 200 hoặc nhiều hơn hình ảnh huấn luyện bình thường cho mỗi danh mục. Tập dữ liệu của chúng tôi (Mục 3) khác với thiết lập này ở ba điểm liên quan đến lựa chọn và đánh giá phương pháp: nó chỉ cung cấp 100 hình ảnh bình thường cho mỗi mẫu sản phẩm thay vì vài trăm, nó không cung cấp bất kỳ mặt nạ thực tế cấp pixel nào, và vị trí và tỷ lệ của đối tượng thay đổi đáng kể trong cùng một mẫu sản phẩm thay vì được căn giữa và đóng khung nhất quán. Sự khác biệt đầu tiên là một lý do hợp

lý giải thích tại sao nỗ lực SuperSimpleNet của chúng tôi hoạt động kém hơn so với kết quả MVTEC AD đã được công bố, vì quá trình huấn luyện lỗi tổng hợp

của phương pháp gốc được xác thực ở quy mô dữ liệu lớn hơn cho mỗi lớp. Sự khác biệt thứ hai là lý do tại sao việc đánh giá định vị của tôi trong toàn bộ báo cáo này mang tính định tính, và nếu có thể định lượng, dựa trên một tập con được chú thích thủ công (Mục 6), thay vì một chỉ số cấp pixel tiêu chuẩn được tính toán dựa trên toàn bộ tập dữ liệu thực tế. Sự khác biệt thứ ba thúc đẩy sự lựa chọn rõ ràng, được thảo luận trong Mục 4, là không cắt ảnh đầu vào ở trung tâm trong quá trình tiền xử lý.



Hình 2.1. Ví dụ ảnh bình thường và ảnh lỗi của một số mẫu sản phẩm.

Bảng 2.1. So sánh các nhóm phương pháp được xem xét.

Nhóm phương pháp	Dữ liệu huấn luyện	Ưu điểm	Hạn chế trong đề tài
PatchCore	Chỉ ảnh bình thường	Không huấn luyện gradient; phù hợp dữ liệu ít	Bản đồ định vị còn thô
DRAEM / SuperSimpleNet	Ảnh bình thường và lỗi giả	Có đầu phân đoạn trực tiếp	Khó hội tụ khi mỗi mẫu chỉ có 80 ảnh huấn luyện
Isolation Forest	Thống kê thủ công từ ảnh bình thường	Đơn giản; chi phí thấp	Khả năng khái quát không đồng đều giữa các mẫu


CHƯƠNG 3. DỮ LIỆU VÀ PHÁT BIỂU BÀI TOÁN

3.1. Tập dữ liệu

Tập dữ liệu bao gồm 12 mẫu sản phẩm thành phần riêng biệt (ký hiệu là FA-504, FA-808, FA-838, FA-924, FA-1041, FA-1042, FA-1043, FA-1045, tất cả có thể nhìn thấy (Hình 1). Mỗi mẫu sản phẩm chứa chính xác 100 hình ảnh bình thường; số lượng hình ảnh có khuyết tật dao động từ 30 đến 53 hình ảnh mỗi mẫu sản phẩm. Sau khi loại bỏ một tập đại diện trùng lặp nằm ngoài hai thư mục con được gắn nhãn của mỗi mẫu sản phẩm, tập dữ liệu có tổng cộng 1705 hình ảnh JPEG duy nhất, không có hình ảnh nào bị hỏng, với dung lượng 474MB. Các hình ảnh chủ yếu có kích thước 956×1276 pixel theo hướng dọc, với một phần nhỏ được xoay 90 sang hướng ngang (1276×956); tỷ lệ hình ảnh được xoay thay đổi đáng kể tùy theo từng loại (ví dụ: 0/150 đối với FA-1041 so với 68/153 đối với

3.2. Sự thay đổi vị trí và kích thước đối tượng

Không giống như các bộ dữ liệu chuẩn được chọn lọc, trong đó đối tượng quan tâm được đặt ở trung tâm và có tỷ lệ nhất quán, các đối tượng trong bộ dữ liệu này được đặt ở các vị trí khác nhau và chiếm các phần khác nhau của khung hình (Hình 2). Sử dụng phương pháp phỏng đoán dựa trên sự khác biệt màu sắc ở các góc để ước tính khung bao cho mỗi hình ảnh, tâm khung bao tương đối bị lệch về phía trên bên trái của khung hình trung bình, và diện tích đối tượng tương đối dao động từ khoảng 3% đến gần 100% của khung hình. Điều này trực tiếp giải thích cho lựa chọn tiền xử lý được mô tả trong Phần 4 (không cắt xén tâm).



Hình 3.1. Phân bố vị trí và kích thước hộp bao đối tượng trong dữ liệu.


3.3. Quy mô khuyết tật

Các khuyết tật quan sát được trong các hình ảnh bị lỗi có kích thước vật lý rất khác nhau, từ các vết nhỏ cục bộ khoảng 30–40 pixel (ở độ phân giải gốc) cho đến các khuyết tật trải rộng trên một phần lớn đối tượng. Sự đa dạng về kích thước này là một yếu tố quan trọng cần xem xét đối với việc giảm độ phân giải trong Phần 6, vì diện tích hiệu dụng của một ô lưới đặc trưng (tính bằng pixel của hình ảnh gốc) phải nhỏ so với các khuyết tật nhỏ nhất để bản đồ bất thường có thể định vị chúng.

3.4. Mất cân bằng dữ liệu

sử dụng hình ảnh bình thường để huấn luyện trong thiết lập một mẫu sản phẩm. (Mục 4), các hình ảnh bị lỗi chỉ đóng vai trò là tập dữ liệu đánh giá. Do số lượng nhỏ, ước tính AUROC trên mỗi lớp về nguyên tắc có thể mang phương sai

đáng kể tùy thuộc vào sự phân chia giữa tập huấn luyện và tập hiệu chuẩn; điều này được xem là một hạn chế trong Mục



Hình 3.2. Số lượng ảnh bình thường và ảnh lỗi theo từng mẫu sản phẩm.

3.5. Phát biểu bài toán

Đối với mỗi mẫu sản phẩm riêng biệt, với một tập dữ liệu huấn luyện chỉ gồm các hình ảnh bình thường, nhiệm vụ gồm hai phần: (a) phân loại ở cấp độ hình ảnh, dự đoán xem hình ảnh thử nghiệm được giữ lại là bình thường hay bị lỗi, và (b) định vị ở cấp độ pixel, tạo ra bản đồ không gian chỉ ra vị trí có khả năng xảy ra lỗi trong hình ảnh bị lỗi. Không có nhãn hoặc mặt nạ lỗi nào được cung cấp trong quá trình huấn luyện.


Bảng 3.1. Tóm tắt tập dữ liệu nghiên cứu.

Thuộc tính	Giá trị / mô tả
Số mẫu sản phẩm	12 mã sản phẩm độc lập
Ảnh bình thường	100 ảnh cho mỗi mẫu; 80 ảnh huấn luyện và 20 ảnh hiệu chuẩn
Ảnh lỗi	30-53 ảnh cho mỗi mẫu; chỉ dùng đánh giá
Tổng số ảnh	1.705 ảnh JPEG, dung lượng khoảng 474 MB
Độ phân giải phổ biến	956 x 1.276 pixel; một phần ảnh xoay ngang
Nhãn pixel	Không có trong dữ liệu gốc
Nhiệm vụ	Phân loại cấp ảnh và định vị vùng lỗi

CHƯƠNG 4. PHƯƠNG PHÁP VÀ THIẾT KẾ HỆ THỐNG

4.1. Tổng quan quy trình OC-MAR

Tôi xây dựng phương pháp của mình dựa trên OC-MAR (Nhận dạng dị thường đa tỷ lệ bị ràng buộc bởi đối tượng), một quy trình chín bước để phát hiện và định vị dị thường một lớp do cố vấn của tôi đề xuất. Các bước bao gồm: (1) ảnh đầu vào, (2) loại bỏ nền để thu được mặt nạ đối tượng, (3) thay đổi kích thước đa tỷ lệ của ảnh đầu vào, (4) phát hiện dị thường trên mỗi tỷ lệ bằng bộ phát hiện một mẫu sản phẩm, (5) tổng hợp đa tỷ lệ các bản đồ dị thường thu được, (6) lọc bị ràng buộc bởi đối tượng, giới hạn các dị thường trong mặt nạ đối tượng, (7) ngưỡng thích ứng được hiệu chỉnh trên tập dữ liệu xác thực bình thường được giữ lại, (8) tinh chỉnh vùng hình thái, và (9) mặt nạ phân đoạn khuyết tật nhị phân cuối cùng. Hình



Hình 4.1. Quy trình OC-MAR gồm chín giai đoạn.

4.2. Tiền xử lý ảnh


Mỗi hình ảnh được điều chỉnh kích thước trực tiếp thành độ phân giải vuông cố định mà không cắt xén phần trung tâm, vì đối tượng cần quan tâm thường nằm lệch tâm (Mục 3); việc cắt xén phần trung tâm có nguy cơ làm mất đi một phần của đối tượng. Các hình ảnh ở chế độ ngang được xoay 90 sang chế độ dọc trước khi thay đổi kích thước, để mạng lưới được hiển thị đầy đủ. Không cần phải học thêm

về tính bất biến xoay. Giá trị pixel được chuẩn hóa bằng cách sử dụng thống kê ImageNet tiêu chuẩn, phù hợp với kiến trúc mạng được huấn luyện trước.

4.3. Loại bỏ nền và tạo mặt nạ đối tượng

Tôi sử dụng mô hình phân đoạn đối tượng nổi bật được huấn luyện trước (isnet-general-use, thông qua rembg) để tách từng đối tượng khỏi nền của nó. Hai cách sử dụng khác nhau của mô hình này được đánh giá. Thứ nhất, như một bước tiền xử lý tập dữ liệu, các pixel nền được thay thế bằng màu đen đồng nhất và các hình ảnh kết quả được đánh giá như một đầu vào thay thế cho PatchCore (Mục 6). Thứ hai, như một nguồn mặt nạ đối tượng được sử dụng trong giai đoạn 6, chúng tôi so sánh hai cách để có được mặt nạ này, (a) một phương pháp phỏng đoán đơn giản, ngưỡng độ sáng pixel trên hình ảnh đã được loại bỏ nền (tiền cảnh = bất kỳ pixel nào có giá trị kênh trên 10), và (b) đầu ra alpha mềm gốc của mô hình, được ngưỡng ở mức 0, 5. Tôi nhận thấy rằng (a) thất bại đáng kể đối với các mẫu sản phẩm có vật liệu đối tượng

có màu tối, vì bước làm phẳng tạo ra tập dữ liệu đã loại bỏ nền sẽ loại bỏ kênh alpha, không còn tín hiệu nào để phân biệt vùng đối tượng tối màu với nền đen mà nó được ghép vào; điều này được định lượng trong Mục 6. Tôi áp dụng (b) làm mặt nạ đối tượng được sử dụng trong cấu hình cuối cùng.




Hình 4.2. So sánh mặt nạ alpha và mặt nạ ngưỡng màu trên vật thể tối.

4.4. Mô hình PatchCore

Tôi sử dụng PatchCore [4] làm bộ phát hiện bất thường một lớp chính (Hình 5), khởi tạo giai đoạn 4 của OC-MAR. Một mạng xương sống WideResNet-50 cố định, được huấn luyện trước trên ImageNet, trích xuất các bản đồ đặc trưng trung gian từ lớp 2 và lớp 3. Mỗi bản đồ đặc trưng được tổng hợp cục bộ với một nhóm trung bình 3×3 và bản đồ lớp 3 được lấy mẫu tăng tuyến tính để phù hợp với độ phân giải không gian của lớp 2 trước khi nối theo kênh, tạo ra một lưới các vector đặc trưng cấp độ mảng cho mỗi hình ảnh. Đối với mỗi lớp, một ngân hàng bộ nhớ được xây dựng bằng cách gộp các đặc trưng và lỗi của tất cả các ảnh huấn luyện thông thường, sau đó lấy mẫu con thông qua lựa chọn tập lõi k-center tham lam để giữ lại một tập con nhỏ, đa dạng các vector đại diện. Trong quá trình suy luận, mỗi vá lỗi của ảnh truy vấn được chấm điểm bằng giá trị Euclidean của nó.

không giám sát cho giai đoạn 4; nỗ lực này không hội tụ đáng tin cậy ở quy mô tập dữ liệu của tôi và được báo cáo là kết quả tiêu cực trong Phụ lục A.



Hình 4.3. Nguyên lý xây dựng ngân hàng bộ nhớ và suy luận của PatchCore [4].

4.5. Đầu vào và tổng hợp đa tỷ lệ

Vì bước tiền hiệu quả của mạng xương sống được cố định so với độ phân giải đầu vào, nên kích thước vật lý của một ô lưới đặc trưng duy nhất, được đo bằng pixel của ảnh gốc, tỷ lệ nghịch với kích thước đầu vào đã chọn. Tôi đánh giá ba độ phân giải đầu vào, 256×256 , 384×384 (được sử dụng xuyên suốt phần còn lại của báo cáo này) và 512×512 , một cách độc lập, để đánh giá ảnh hưởng của độ chi tiết lưới đến việc định vị các khuyết tật nhỏ (Mục 3). Ngoài ra, tôi kết hợp ba bản đồ bất thường trên mỗi tỷ lệ thành một bản đồ duy nhất (giai đoạn 5 của OC-MAR) bằng cách thay đổi kích thước từng bản đồ thành một khung chung và lấy giá trị tối đa theo từng phần tử, với điểm số tổng hợp ở cấp độ ảnh được lấy là giá trị tối đa của ba điểm số trên mỗi tỷ lệ. Mục 6 báo cáo rằng sự

kết hợp này không cải thiện AUROC trung bình so với cấu hình 384×384 đơn tỷ lệ; Chúng tôi giữ nguyên cấu hình 384×384 làm cấu hình cuối cùng và báo cáo kết quả tổng hợp là một phát hiện tiêu cực thay vì chấp nhận nó.

4.6. Loại giới hạn đối tượng và tinh chỉnh vùng

Bản đồ nhiệt bất thường thô được phân ngưỡng để trực quan hóa và sử dụng tiếp theo. Tôi so sánh hai biến thể. Trong biến thể đơn giản, ngưỡng phần trăm (ví dụ: phần trăm thứ 92) được tính toán trên toàn bộ bản đồ nhiệt, bao gồm cả các pixel nền. Trong biến thể bị ràng buộc bởi đối tượng, ngưỡng phần trăm tương tự chỉ được tính toán trên các pixel nằm trong mặt nạ đối tượng (Mục 4. 3), và chỉ thành phần liên thông lớn nhất trong số các pixel đã được phân ngưỡng được giữ lại

như một hình thức tinh chỉnh vùng đơn giản, loại bỏ các phát hiện giả nhỏ. Bước tinh chỉnh vùng đầy đủ hơn bằng cách sử dụng phép mở và đóng hình thái học (giai đoạn 8 của OC-MAR) vẫn chưa được đánh giá.

4.7. Phân ngưỡng

Các mục 4. 6 và 6 ở trên sử dụng một ngưỡng phân vị thứ 92 cố định duy nhất cho tất cả 12 lớp. Ngoài ra, tôi hiệu chỉnh ngưỡng này cho từng lớp, sử dụng phép chia chuẩn hiệu chỉnh (Mục 5), đối với mỗi lớp, tôi chọn phân vị ứng viên nhỏ nhất trong {92, 94, 96, 98, 99} có diện tích dương tính giả trung bình được giữ lại trên ảnh chuẩn hiệu chỉnh của lớp đó nằm ở mức bằng hoặc thấp hơn mục tiêu cố định 300 pixel. Mục 6 báo cáo rằng điều này làm giảm diện tích dương tính giả trung bình trên tất cả 12 lớp xuống 66% so với phân vị thứ 92 cố định, mà không làm thay đổi ngân hàng bộ nhớ hoặc điểm số bất thường ở cấp độ hình ảnh.

Bảng 4.1. Chức năng của các giai đoạn OC-MAR.

Giai đoạn	Tên	Vai trò
1	Tiếp nhận ảnh	Chuẩn hóa hướng và kích thước
2	Tách nền	Lấy ảnh đối tượng và mặt nạ alpha
3	Tạo nhiều tỷ lệ	256, 384 và 512 pixel
4	Phát hiện bất thường	PatchCore độc lập theo mẫu sản phẩm
5	Tổng hợp	Đưa bản đồ về cùng kích thước và lấy cực đại
6	Giới hạn tiền cảnh	Loại phản hồi ngoài mặt nạ đối tượng
7	Ngưỡng thích ứng	Hiệu chuẩn phân vị theo từng mẫu
8	Tinh chỉnh vùng	Giữ thành phần liên thông lớn nhất
9	Xuất kết quả	Điểm cấp ảnh, bản đồ nhiệt và mặt nạ nhị phân

CHƯƠNG 5. THIẾT LẬP THỰC NGHIỆM

5.1. Quy trình phân chia dữ liệu

Đối với mỗi mẫu sản phẩm, 100 hình ảnh bình thường được chia theo tỷ lệ 80/20 thành một tập dữ liệu huấn luyện dùng làm bộ nhớ và một tập dữ liệu hiệu chuẩn bình thường được giữ lại, sử dụng một hạt giống ngẫu nhiên cố định được chia sẻ trong tất cả các thí nghiệm được báo cáo ở đây. Tất cả các ảnh lỗi đều được giữ lại để đánh giá và không bao giờ được dùng để xây dựng bộ nhớ. Việc phát hiện ở cấp độ ảnh được đánh giá trên tập hợp các ảnh bình thường được giữ lại (nhãn 0) và tất cả các ảnh lỗi thuộc mẫu sản phẩm đó (nhãn 1).

5.2. Chỉ số đánh giá

Chỉ số định lượng chính là AUROC cấp độ hình ảnh, được tính toán cho mỗi lớp và tính trung bình trên 12 mẫu sản phẩm, được báo cáo cả cho một điểm khởi đầu cố định duy nhất và, trong Phần 6. 6, dưới dạng giá trị trung bình $\pm$ độ lệch chuẩn trên 5 điểm khởi đầu. Chất lượng định vị chủ yếu được đánh giá định tính thông qua lớp phủ bản đồ nhiệt trên các hình ảnh bị lỗi (Phần 6), vì tập dữ liệu không cung cấp mặt nạ tham chiếu cấp độ pixel (Phần 3). Ngoài ra, tôi cũng trình bày kết quả đánh giá định vị định lượng một phần (IoU, thước đo độ chồng lấp vùng ngưỡng đơn và độ chính xác của trò chơi chỉ điểm) đối với một tập hợp con các hình ảnh bị lỗi được chú thích thủ công trong Phần 6. 10.

5.3. Tỷ lệ coreset

Tỷ lệ lấy mẫu con của coreset được đặt ở mức 2% dung lượng bộ nhớ thô, được chọn sau khi so sánh thực nghiệm thời gian huấn luyện thực tế với mức 10%, trên phần cứng GPU hiện có, 5 phút so với 14 phút trên tất cả 12 lớp cho cấu hình độ phân giải đầy đủ (224×224).

5.4. Các cấu hình so sánh

Tôi trình bày kết quả cho các cấu hình sau, mỗi cấu hình thể hiện một quyết định thiết kế riêng biệt.

1. Đường cơ sở, PatchCore trên ảnh gốc (không xóa nền), đầu vào 224×224 , naïve Phân ngưỡng phần trăm toàn bộ hình ảnh.
2. Loại bỏ nền, giống hệt với cơ sở ngoại trừ biến hình ảnh đã loại bỏ nền-Từ "ant" được sử dụng.
lọc thành phần liên thông lớn nhất (Mục 4. 6).
3. Độ phân giải cao hơn, như trên, với độ phân giải đầu vào tăng từ 224×224 lên 384×384 .

5.5. Đường cơ sở thống kê cổ điển

Để so sánh hiệu suất của PatchCore với một phương pháp thay thế không dựa trên học sâu, tôi đánh giá một đường cơ sở một lớp cổ điển bằng cách sử dụng các thống kê hình ảnh được tạo thủ công được tính toán trong quá trình phân tích dữ liệu thăm dò, độ sáng, độ tương phản, độ sắc nét, mật độ cạnh, độ bão hòa, bốn mô tả ma trận đồng xuất hiện mức độ xám (GLCM) (độ tương phản, độ đồng nhất, năng lượng, tương quan) và entropy mẫu nhị phân cục bộ (LBP), tổng cộng mười đặc trưng trên mỗi hình ảnh. Đối với mỗi mẫu sản phẩm, một Rừng cô lập [2] (200 bộ ước lượng) được huấn luyện trên các đặc trưng được chuẩn hóa chỉ của các hình ảnh huấn luyện bình thường, phản ánh giao thức một mẫu sản phẩm của PatchCore; điểm số bất thường thu được được đánh giá bằng AUROC so với cùng một tập

nhân được sử dụng cho PatchCore. Một điểm khác biệt về phương pháp luận so với giao thức PatchCore đáng chú ý là đường cơ sở này được đánh giá trên tất cả các hình ảnh bình thường của một lớp (thay vì chia tách 20%), vì ban đầu nó được tính toán như một phần của phân tích thăm dò chứ không phải là một đánh giá giữ lại; Điều này khiến cho chỉ số AUROC được báo cáo, nếu có thể nói, có phần lạc quan so với đánh giá mà PatchCore đưa ra trước đó.

5.6. Phương pháp thay thế

Để so sánh thêm, tôi cũng đã cố gắng huấn luyện SuperSimpleNet [3], một phương pháp phân đoạn có thể huấn luyện không giám sát tổng hợp các khiếm khuyết giả thông qua nhiều Perlin được đưa vào không gian đặc trưng, trên hai lớp có AUROC PatchCore cơ bản thấp nhất. So sánh này và kết quả của nó được báo cáo trong Phụ lục A.

Bảng 5.1. Các cấu hình thực nghiệm chính.

Cấu hình	Ảnh đầu vào	Độ phân giải	Hậu xử lý
C1 - Cơ sở	Ảnh gốc	224 x 224	Ngưỡng phân vị toàn ảnh
C2 - Tách nền	Ảnh đã loại nền	224 x 224	Ngưỡng phân vị toàn ảnh
C3 - Giới hạn tiền cảnh	Ảnh đã loại nền	224 x 224	Mặt nạ alpha và thành phần lớn nhất
C4 - Cấu hình cuối	Ảnh đã loại nền	384 x 384	Giới hạn tiền cảnh và thành phần lớn nhất
C5 - Đa tỷ lệ	Ảnh đã loại nền	256/384/512	Tổng hợp cực đại và giới hạn tiền cảnh

CHƯƠNG 6. KẾT QUẢ VÀ ĐÁNH GIÁ

6.1. Hiệu suất phát hiện cơ sở

Giá trị AUROC trung bình trên các lớp là 0,991, với 5 trong số 12 mẫu sản phẩm đạt giá trị tuyệt đối 1,000 và các lớp yếu nhất, FA-1047 (0,964) và FA-808 (0,970), vẫn cao hơn 0,95.

6.2. So sánh với đường cơ sở thống kê

Chỉ số AUROC trung bình của phương pháp chuẩn cổ điển là 0,898, thấp hơn hơn 9 điểm so với chỉ số chuẩn của PatchCore. cấu hình (0,991) và thấp hơn gần 10 điểm so với cấu hình cuối cùng của PatchCore (0,996, Bảng 5). Khoảng cách này chủ yếu xuất phát từ một số ít các mẫu sản phẩm mà số liệu thống kê được tính toán thủ công rõ ràng là không phù hợp. Không đủ, FA-808, FA-924 và FA-838 đều thấp hơn 0,82 so với mức cơ sở cổ điển trong khi vẫn duy trì trên 0,97 đối với PatchCore. Độ phân tán theo từng mẫu sản phẩm của đường cơ sở cổ điển cũng rộng hơn đáng kể (0,799) (đến 0,993) so với PatchCore (0,964 đến 1,000 trong cấu hình cơ bản), cho thấy rằng khả năng học hỏi đã được cải thiện.

Các đặc điểm sâu có khả năng khái quát hóa nhất quán hơn trên 12 loại đối tượng khác nhau so với các đặc điểm khác. Bộ tính năng cố định, được thiết kế thủ công.

Bảng 6.1. AUROC của Isolation Forest và PatchCore cơ sở.

Mẫu	Isolation Forest	PatchCore
FA-504	0,993	1,000
FA-808	0,799	0,970
FA-838	0,814	0,996
FA-924	0,799	1,000
FA-1041	0,928	0,996
FA-1042	0,845	0,981
FA-1043	0,965	0,991
FA-1045	0,833	0,995

Mẫu	Isolation Forest	PatchCore
FA-1047	0,958	0,964
FA-1113	0,946	1,000
FA-1114	0,978	1,000
FA-1120	0,922	1,000
Trung bình	0,898	0,991

6.3. Ảnh hưởng của bước loại bỏ nền

không thay đổi (0, 991 trong cả hai cấu hình), nhưng sự chênh lệch giữa các lớp là không nhỏ ở cả hai hướng. Việc loại bỏ nền cải thiện đáng kể FA-1047 (+0, 036) nhưng làm giảm FA-1043 (0, 021) và Việc thêm nền đen do quá trình loại bỏ nền, khi kết hợp với phương pháp phân ngưỡng phần trăm toàn bộ ảnh đơn giản, sẽ làm biến dạng ngưỡng và tạo ra các vùng định vị rộng hơn so với ban đầu. Ngược lại với kỳ vọng ban đầu rằng việc loại bỏ nền sẽ giúp cải thiện khả năng định vị. Điều này thúc đẩy việc áp dụng ngưỡng giới hạn đối tượng tiền cảnh được mô tả trong Phần 4. 6.

6.4. Sai lệch mặt nạ đối với vật thể tối

Mục 4. 3 mô tả hai cách để thu được mặt nạ đối tượng được sử dụng cho ngưỡng giới hạn tiền cảnh, một ngưỡng độ sáng màu đơn giản trên ảnh đã được loại bỏ nền, và đầu ra alpha mềm gốc của mô hình phân đoạn. Tôi định lượng sự khác biệt giữa chúng bằng cách lấy mẫu 10 ảnh bình thường. hình ảnh cho mỗi mẫu sản phẩm, tính toán cả hai mặt nạ và đo tỷ lệ pixel vật thể thực (alpha). > 0, 5) mặt nạ ngưỡng màu dán nhãn sai là nền (tỷ lệ âm tính giả). Bảng 4 Báo cáo kết quả cho từng lớp, cùng với độ sáng trung bình của vùng đối tượng thực.

Đối với 9 trong số 12 mẫu sản phẩm, hai loại mặt nạ cho kết quả gần như tương đồng (tỷ lệ âm tính giả dưới 7%). Đối với ba mẫu sản phẩm còn lại, Ba mẫu sản phẩm này có màu sắc trung bình của vật thể tối nhất trong tập dữ liệu (lần lượt là 28, 7, 31, 6 và 4, 7 trên thang điểm 0–255), và có mối tương quan giữa tỷ lệ âm

tính giả và độ sáng trung bình của vật thể. Hệ số tương quan r trên tất cả 12 lớp là $r = 0,938$. Cơ chế là do bước loại bỏ nền của tôi kết hợp các yếu tố sau: đối tượng được phân đoạn trên nền đen đồng nhất và loại bỏ kênh alpha; khi đối tượng Bản thân vật liệu có màu tối, giá trị pixel của nó sau khi ghép ảnh không thể phân biệt được với nền.


Chỉ riêng độ sáng. Hình 6 minh họa trực tiếp điều này cho FA-1047, mặt nạ ngưỡng màu chính xác. Hình ảnh thể hiện rõ các nhân vật có màu sắc tươi sáng nhưng lại bỏ sót gần như toàn bộ phần để tối màu nối liền chúng. Trong đó mặt nạ alpha thực sự bao gồm một cách chính xác. Tôi lưu ý một hạn chế quan trọng được phát hiện trong quá trình chuẩn bị các ví dụ định tính, đó là định lượng này. được thực hiện trên các hình ảnh bình thường. Khi tôi kiểm tra các hình ảnh FA-1047 bị lỗi cụ thể được sử dụng Đối với các số liệu định tính trong phần tiếp theo, hai loại mặt nạ cho kết quả gần giống nhau (âm tính giả).

Bài học về phương pháp luận: một số ít ví dụ được kiểm tra bằng mắt thường có thể không tiết lộ được vấn đề thực sự. Vấn đề mang tính hệ thống mà chỉ có phân tích định lượng toàn diện mới phát hiện ra. Xét đến sự thất bại đã được chứng minh trên. .. Đối với ảnh thông thường, và phù hợp với Mục 4. 3, tôi sử dụng mặt nạ alpha thực làm mặt nạ đối tượng. trong cấu hình cuối cùng của chúng tôi.

Bảng 6.2. Sai lệch của mặt nạ ngưỡng màu so với mặt nạ alpha.

Mẫu	Tỷ lệ âm tính giả	Độ sáng trung bình
FA-1120	0,963	4,7
FA-1047	0,825	28,7
FA-1114	0,780	31,6
FA-1113	0,064	133,2
FA-1042	0,047	132,8
FA-1043	0,042	139,5
FA-1045	0,040	132,4
FA-838	0,007	152,5
FA-1041	0,003	171,6
FA-924	0,003	128,7

Mẫu	Tỷ lệ âm tính giả	Độ sáng trung bình
FA-504	0,003	117,6
FA-808	0,002	200,9



Hình 6.1. Vật thể tối bị bỏ sót khi tái tạo mặt nạ bằng ngưỡng màu.

6.5. Cấu hình cuối cùng và độ phân giải đầu vào

Đầu vào 384×384 , ngưỡng phần trăm giới hạn vùng tiền cảnh với thành phần liên thông lớn nhất. lọc. Giá trị AUROC trung bình được cải thiện lên 0,996, tăng từ 0,991 của đường cơ sở ban đầu và 0,991. Chỉ riêng việc loại bỏ nền ở độ phân giải 224×224 . Hiện tại, mọi mẫu sản phẩm đều đạt điểm từ 0,983 trở lên, và.. Các lớp yếu nhất trước đây không còn là ngoại lệ rõ ràng nữa, FA-1047 đạt điểm tuyệt đối 1.000 và FA-808 cải thiện lên 0.983 (từ 0.970 ở mức cơ bản và 0.955 ở mức 224×224 đã loại bỏ nền). (cấu hình). Mẫu sản phẩm có chỉ số thấp nhất là FA-1120 với 0,987, vẫn ở mức khá cao.

So sánh định tính trên hai mẫu sản phẩm ban đầu yếu nhất (FA-1047, FA-808) cho thấy rằng việc giới hạn ngưỡng phần trăm vào mặt nạ tiền cảnh và chỉ giữ lại thành phần liên thông lớn nhất giúp thu hẹp đáng kể vùng cục bộ so với ngưỡng

toàn ảnh đơn giản, trên cả ảnh bị lỗi (định vị chính xác) và ảnh bình thường (không quan sát thấy vùng dương tính giả lớn). Tăng độ phân giải đầu vào từ 224×224 lên 384×384 giúp thu hẹp hơn nữa việc định vị, và trong một trường hợp đã phát hiện ra một vùng lỗi thực sự nhỏ hoàn toàn không được phát hiện ở độ phân giải 224×224 , phù hợp với lập luận về dấu vết ô lưới trong Phần 4. 5.

Tôi lưu ý một chi tiết triển khai ảnh hưởng đến cấu hình này: ở độ phân giải đầu vào 384×384 , tập hợp các đặc trưng thô (trước khi thiết lập lại lỗi) lớn hơn khoảng 3 lần so với ở độ phân giải 224×224 (vì độ phân giải lưới đặc trưng tỷ lệ thuận với kích thước đầu vào), điều này khiến việc lựa chọn lỗi k-center tham lam trở nên quá chậm; tôi đã giới hạn tập hợp thô thông qua lấy mẫu con ngẫu nhiên ở mức 65. 000 điểm (tương đương với kích thước tập hợp thô ở độ phân giải 224×224) trước khi lựa chọn lỗi, khôi phục thời gian chạy thực tế mà không làm giảm chất lượng bộ nhớ, theo như tôi nhận thấy từ các kết quả trên.

dạng đường viền màu xanh lá cây, như các hình ảnh bên dưới cho thấy; bản thân vùng được ngưỡng bên dưới đã chính xác.

Bảng 6.3. AUROC của cấu hình cuối cùng theo từng mẫu sản phẩm.

Mẫu	AUROC	Mẫu	AUROC
FA-504	1,000	FA-1043	0,996
FA-808	0,983	FA-1045	1,000
FA-838	1,000	FA-1047	1,000
FA-924	1,000	FA-1113	0,995
FA-1041	1,000	FA-1114	0,994
FA-1042	1,000	FA-1120	0,987
Trung bình	0,996		

6.6. Độ ổn định theo hạt giống ngẫu nhiên

Mọi kết quả được báo cáo ở trên đều sử dụng một hạt giống ngẫu nhiên cố định duy nhất (Mục 5), hạt giống này xác định cả việc phân chia tập huấn luyện/hiệu chuẩn và việc lấy mẫu con của tập lỗi; do số lượng ảnh lỗi nhỏ. Đối với

mỗi mẫu sản phẩm (Mục 3), Tôi đã đánh dấu AUROC trên mỗi mẫu sản phẩm là một hạn chế vì nó mang phương sai đáng kể. Chúng tôi lặp lại cấu hình cuối cùng (hình ảnh đã loại bỏ nền, đầu vào 384×384) trên 5 hạt giống. (0–4), mỗi nhóm có một bộ dữ liệu huấn luyện/hiệu chuẩn được lấy mẫu lại độc lập và bộ lỗi. Bảng 6 báo cáo Giá trị trung bình và độ lệch chuẩn của từng lớp.

tách ra.

Bảng 6.4. AUROC trung bình và độ lệch chuẩn trên năm hạt giống.

Mẫu	AUROC trung bình	Độ lệch chuẩn
FA-1120	0,982	0,014
FA-1042	0,992	0,005
FA-924	0,992	0,011
FA-1113	0,993	0,005
FA-808	0,996	0,008
FA-1114	0,998	0,003
FA-1045	0,999	0,002
FA-1043	0,999	0,001
FA-1047	1,000	0,000
FA-1041	1,000	0,000
FA-504	1,000	0,000
FA-838	1,000	0,000

6.7. Đánh giá tổng hợp đa tỷ lệ

Mục 4. 5 đã đánh giá kích thước 224×224 và 384×384 một cách độc lập chứ không phải kết hợp. Bây giờ chúng ta sẽ đánh giá Tổng hợp đa quy mô thực sự (giai đoạn 5 của OC-MAR), chạy PatchCore độc lập ở ba đầu vào. các độ phân giải 256×256 , 384×384 và 512×512 , điều chỉnh kích thước mỗi bản đồ nhiệt thu được về cùng một độ phân giải. Khung vẽ 384×384 , và kết hợp chúng theo từng phần tử bằng cách lấy giá trị tối đa. Mức độ hình ảnh tổng hợp Điểm số này cũng là điểm tối đa trong ba điểm số trên mỗi thang đo. Bảng 7 so sánh điểm số tổng hợp này.


Cầu hình được so sánh với cầu hình 384×384 riêng lẻ, được đánh giá trong cùng một lần chạy để có sự so sánh công bằng. Việc tổng hợp đa thang đo theo giá trị cực đại không cải thiện AUROC trung bình, mà chỉ làm giảm nhẹ. (0, 9964 so với 0, 9958), gần như hoàn toàn do hai mẫu sản phẩm, FA-1113 (0, 007) và FA-1120 (0, 005), trong khi năm mẫu sản phẩm không thay đổi và ba mẫu sản phẩm cải thiện rất nhẹ. Việc lấy giá trị tối đa theo từng phần tử trên các thang đo kết hợp bằng chứng một cách lạc quan cho thấy, nó có khả năng lan truyền chính xác như nhau.

để đảm bảo tính ổn định (một lỗi dương tính giả đơn lẻ ở một thang đo duy nhất sẽ không lan truyền vào kết quả tổng hợp cuối cùng) mà không làm thay đổi kết luận tổng thể của chúng tôi, với kích thước khuyết tật hiện có trong tập dữ liệu này, kích thước 384×384 là phù hợp. Độ phân giải đã được sử dụng xuyên suốt phần còn lại của báo cáo này đáp ứng được yêu cầu, và đa thang đo. Việc tổng hợp dữ liệu làm tăng chi phí suy luận lên khoảng gấp 3 lần so với Mục 6 mà không mang lại lợi ích ròng nào về AUROC. Có thể Điều này vẫn có thể được đảm bảo đối với các tập dữ liệu có phạm vi kích thước vật lý của khuyết tật rộng hơn so với những gì đã quan sát được trong Phần 3.

Bảng 6.5. So sánh đơn tỷ lệ và tổng hợp đa tỷ lệ.

Mẫu	384 x 384	Đa tỷ lệ
FA-504	1,000	1,000
FA-808	1,000	1,000
FA-838	1,000	1,000
FA-924	1,000	1,000
FA-1041	1,000	0,999
FA-1042	0,995	0,994
FA-1043	0,994	0,999
FA-1045	0,997	0,998
FA-1047	0,999	0,999
FA-1113	1,000	0,993
FA-1114	0,995	0,995

Mẫu	384 x 384	Đa tỷ lệ
FA-1120	0,977	0,973
Trung bình	0,996	0,996



Hình 6.2. Bản đồ bất thường theo từng tỷ lệ và kết quả tổng hợp.

6.8. Ngưỡng thích ứng theo từng mẫu

Mục 6 ở trên chứng minh rằng một vùng dương tính giả nhỏ còn sót lại trên hầu hết mọi trường hợp. Hình ảnh bình thường dưới ngưỡng phân vị thứ 92 cố định, không hiệu chỉnh được sử dụng xuyên suốt báo cáo này. Chúng tôi đánh giá một phương án thích ứng theo từng lớp (giai đoạn 7 của OC-MAR), đối với mỗi lớp, tôi đo lường giá trị trung bình. diện tích thành phần liên thông lớn nhất được giữ lại trên đường phân chia chuẩn hiệu chuẩn của lớp đó (Mục 5) tại năm các phân vị ứng viên (92, 94, 96, 98, 99), và chọn ứng viên nhỏ nhất có giá trị trung bình được giữ lại.

khu vực nằm ở mức hoặc thấp hơn mục tiêu cố định là 300 pixel (khoảng 0, 2% của khung vẽ 384×384), Thay vì áp dụng phân vị thứ 92 một cách đồng đều. Quá trình hiệu chuẩn này chỉ sử dụng các hình ảnh bình thường và Nó không làm thay đổi ngân hàng bộ nhớ hoặc điểm số bất thường ở cấp độ hình ảnh, do đó không ảnh hưởng đến AUROC. Kết quả đã được báo cáo trước đó trong phần này. tại phân trăm thứ 92 cố định để so sánh. Mỗi lớp đều đạt mục tiêu 300 pixel. ở mức phân trăm từ 94 đến 99 tùy thuộc vào từng nhóm, và diện tích dương tính giả trung bình trên tất cả các nhóm.

Tôi kỳ vọng điều này sẽ giúp làm rõ hơn các lớp phủ hình ảnh thông thường được hiển thị ở đó mà không làm thay đổi đáng kể cấu trúc. việc định vị hình ảnh bị lỗi, vì điểm số bất thường của vùng lỗi thực sự về cơ bản là như vậy đối với tất cả Các mẫu được kiểm tra trong báo cáo này được tách biệt rõ ràng khỏi mức nền của hình ảnh bình thường (Hình 11).

Bảng 6.6. Hiệu quả ngưỡng thích ứng theo mẫu sản phẩm.

Mẫu	Phân vị chọn	FP tại p92	FP sau hiệu chỉnh
FA-1114	99	1.244,5	196,4
FA-1113	99	1.171,8	187,3
FA-1047	98	846,3	253,1
FA-1043	98	634,8	219,1
FA-1042	98	618,4	223,0


Mẫu	Phân vị chọn	FP tại p92	FP sau hiệu chỉnh
FA-1041	98	562,9	175,2
FA-1045	96	577,9	293,7
FA-808	98	543,7	195,8
FA-1120	98	530,7	163,2
FA-924	96	432,7	260,2
FA-838	96	410,7	240,2
FA-504	94	374,5	288,0
Trung bình	-	662,4	224,6

6.9. Đánh giá định tính khả năng định vị


tương ứng, ở độ phân giải 384×384 . Trong cả hai lớp, ngưỡng phần trăm toàn bộ hình ảnh đơn giản. (cột giữa) bao phủ hầu hết thân đối tượng, trong khi ngưỡng giới hạn tiền cảnh với Lọc thành phần liên thông lớn nhất (cột bên phải) cô lập một vùng nhỏ, ổn định, gần Mũ dành cho FA-808 và gần hình bên trái nhất dành cho FA-1047, mà tôi cho là vị trí lỗi thực sự. Với tính nhất quán trên các mẫu lỗi độc lập. Hình 10 cho thấy quy trình hạn chế vùng tiền cảnh tương tự được áp dụng cho các hình ảnh FA-808 bình thường được giữ lại, không có vùng dương tính giả lớn nào.

được tạo ra, cho thấy việc thiết lập ngưỡng chặt chẽ hơn không dẫn đến việc phát hiện sai. Nguyên liệu đầu vào không có lỗi. Quy trình giới hạn ở phía trước không chỉ được điều chỉnh cho hai mẫu này, Hình 11 áp dụng quy trình giống hệt nhau, không thay đổi, cho một mẫu bình thường và một mẫu lỗi từ mỗi trong số 10 mẫu còn lại. các lớp được đặt cạnh nhau để so sánh trực tiếp. Đối với mẫu lỗi trong 9 trên 10 mẫu sản phẩm, Vùng được giữ lại là một mảng nhỏ, có tính liên tục về mặt không gian chứ không phải là một khối phân tán, phù hợp với Các ví dụ FA-808 và FA-1047 ở trên. Trong mẫu FA-1041 được hiển thị, không có vùng nào còn sót lại.

Trong phần này, một số vùng dương tính giả nhỏ còn sót lại trên hầu hết mọi hình ảnh bình thường tại điểm hoạt động này, và đó chính là lý do cho việc hiệu chỉnh thích ứng theo từng lớp. ngưỡng được đánh giá trong Phần 6. 8, và làm giảm diện tích dương tính giả trung bình xuống 66% so với. .. Ngưỡng cố định được sử dụng trong hình trên. Điểm số bất thường ở cấp độ hình ảnh s được hiển thị trong Hình 11 là Tuy nhiên, tỷ lệ này luôn thấp hơn đáng kể đối với mẫu bình thường so với mẫu bị lỗi. trong mỗi một trong 10 mẫu sản phẩm, do đó các kết quả dương tính giả còn lại trong quá trình định vị không chuyển thành Lỗi phân loại ở cấp độ hình ảnh tại đây.



Hình 6.3. Kết quả định vị trên ảnh lỗi: (a) FA-808; (b) FA-1047.



Hình 6.4. Đối chiếu định vị: (a) ảnh bình thường FA-808; (b) các mẫu sản phẩm còn lại.

6.10. Đánh giá định lượng trên tập chú thích thủ công

Đánh giá định tính nêu trên, về bản chất, không thể trả lời một câu hỏi cơ bản: liệu vùng được giữ lại có thực sự trùng khớp với vùng bị lỗi hay không, ngoài một vài ví dụ đã được trình bày. Tập dữ liệu không cung cấp dữ liệu tham chiếu ở cấp độ pixel, vì vậy tôi đã xây dựng một phần dữ liệu tham chiếu đó. Đối với mỗi mẫu sản phẩm, tôi đã chú thích thủ công một mẫu hình ảnh bị lỗi được phân tầng, nhắm mục tiêu vào 40% số hình ảnh bị lỗi của mẫu sản phẩm đó, được chia cho hai người chú thích, sử dụng một công cụ trình duyệt được xây dựng riêng (một hình ảnh tham chiếu bình thường được hiển thị bên cạnh mỗi hình ảnh bị lỗi để chú thích) ghi lại một vùng nhị phân được vẽ tay thay vì một đa giác chính xác. Lựa chọn này là có chủ ý chứ không phải là một lối tắt, vì việc phân đoạn chính xác đến từng pixel

đòi hỏi chuyên môn và thời gian của người chú thích, điều hiếm khi có sẵn trong môi trường sản xuất nhỏ mà báo cáo này nhắm đến, vì vậy một giao thức chú thích thô, nhanh chóng được cho là dữ liệu tham chiếu đại diện hơn để đánh giá khả năng triển khai thực tế, với chi phí là ranh giới lỏng lẻo hơn so với mặt nạ do chuyên gia vẽ. Với một ranh giới thực tế được xác định một cách thô sơ và cố ý không chính xác, một chỉ số chồng lấp ranh giới nghiêm ngặt như giao điểm trên

hợp nhất (IoU) được cho là sẽ mang tính bi quan; một vị trí được xác định chính xác về mặt kỹ thuật vẫn có thể đạt điểm IoU thấp nếu vùng được vẽ thủ công lớn hơn hoặc nhỏ hơn phạm vi khuyết tật thực sự.

Do đó, tôi báo cáo ba số liệu bổ sung so với cùng một dự đoán thành phần liên kết lớn nhất bị hạn chế ở tiền cảnh được sử dụng trong suốt phần này (ngưỡng phân vị thứ 92 cố định), IoU; phạm vi bao phủ, phần trăm vùng được chú thích bằng tay mà vùng được dự đoán chồng lấn ($|\text{pred} \cap \text{gt}|/|\text{gt}|$, một thước đo chồng lấn vùng ngưỡng đơn, không phải là đường cong PRO đa ngưỡng đầy đủ của [1]); và độ chính xác trò chơi chỉ điểm [6], liệu pixel có điểm số cao nhất của bản đồ nhiệt bất thường thô có nằm bên trong vùng được chú thích bằng tay hay không, một số liệu hoàn toàn không phụ thuộc vào ranh giới của vùng được dự đoán.

được chú thích là "không thấy khuyết tật rõ ràng" và bị loại trừ, vì IoU và độ phủ không được xác định so với dữ liệu tham chiếu trống). IoU trung bình thấp (0, 220), phù hợp với kỳ vọng của tôi dựa trên dữ liệu tham chiếu thô. Độ phủ trung bình cao hơn (0, 313) nhưng vẫn ở mức khiêm tốn. Độ chính xác của trò chơi chỉ trở cao hơn đáng kể (0, 875), trong 10 trên 12 mẫu sản phẩm, pixel có điểm số cao nhất nằm bên trong vùng khuyết tật được chú thích thủ công trên 80–100% số hình ảnh được chú thích. Nhìn chung, ba con số này kể một câu chuyện nhất quán: khả năng định vị của mô hình không hoàn toàn chính xác đến từng ranh giới so với cảm nhận của con người về phạm vi khuyết tật, nhưng đối với hầu hết các loại khuyết tật, nó lại rất đáng tin cậy trong việc chỉ ra đúng vị trí tổng quát, đây là thuộc tính hữu

Ở đây nên được hiểu là giới hạn dưới, một phần là do sự lỏng lẻo trong chú thích chứ không phải là một giới hạn thuần túy. Mức độ chính xác của mô hình.

Bảng 6.7. Chỉ số định vị trên 192 ảnh được chú thích thủ công.

Mẫu	n	IoU	Độ phủ	Pointing game
FA-808	20	0,323	0,564	0,800
FA-1041	20	0,289	0,361	0,950
FA-1043	16	0,258	0,329	1,000

Mẫu	n	IoU	Độ phủ	Pointing game
FA-1047	12	0,222	0,229	1,000
FA-1042	16	0,214	0,369	1,000
FA-1113	12	0,212	0,225	1,000
FA-1045	12	0,209	0,237	1,000
FA-504	20	0,206	0,352	0,700
FA-924	12	0,199	0,242	0,917
FA-838	20	0,194	0,269	0,900
FA-1120	12	0,179	0,206	1,000
FA-1114	20	0,116	0,213	0,500
Trung bình	192	0,220	0,313	0,875



Hình 6.5. Ví dụ đối chiếu vùng dự đoán với mặt nạ chú thích thủ công.

CHƯƠNG 7. THẢO LUẬN

7.1. Ý nghĩa của kết quả

Một bộ dò không cần huấn luyện là lựa chọn mặc định hợp lý ở quy mô dữ liệu này, nhưng khả năng định vị của nó. .. Cần trợ giúp. PatchCore đạt được AUROC trung bình ở cấp độ hình ảnh là 0,996 chỉ với 80 lần huấn luyện thông thường. hình ảnh cho mỗi mẫu sản phẩm và không có huấn luyện dựa trên gradient nào ngoài việc chọn coreset, đó là lý do chính. chúng tôi đã sử dụng nó làm bộ dò chính thay vì mạng phân đoạn có thể huấn luyện (Mục 4). Sự đánh đổi ở đây là kết quả định vị của nó là hệ quả gián tiếp của lưới khoảng cách giữa các vùng, chứ không phải là một đầu phân đoạn được huấn luyện trực tiếp và quy trình xử lý hậu kỳ các quyết định trong Phần 4. 6, Hạn chế tiền cảnh, lọc thành phần liên thông lớn nhất, bằng chứng đa thang đo, tồn tại đặc biệt để bù đắp cho

(Hình 11) cho thấy một số vùng dương tính giả nhỏ vẫn tồn tại sau ngưỡng cố định của tôi trên hầu hết mọi hình ảnh bình thường mà tôi đã kiểm tra, không chỉ hai lớp yếu nhất theo AUROC, mặc dù không có vùng nào trong số đó đủ lớn để làm cho điểm số ở cấp độ hình ảnh tương ứng vượt quá mức bị lỗi. Bài học chung rút ra là việc kiểm tra định tính trên một lớp hoặc một ví dụ duy nhất không thể thay thế cho việc kiểm tra toàn bộ các mẫu sản phẩm, ngay cả trong một bài báo cáo mà việc đánh giá chính được thực hiện một cách có chủ ý là định tính.

7.2. Ảnh hưởng của tiền xử lý và hậu xử lý

Các lựa chọn tiền xử lý tương chừng miến phí không phải lúc nào cũng miễn phí. Việc loại bỏ nền được áp dụng để cho phép phân ngưỡng giới hạn đối tượng trước mà hầu như không tốn thêm chi phí, và nó đã cải thiện nhẹ chỉ số AUROC trung bình (từ 0,991 lên 0,996, Bảng 3). Nhưng cách cụ thể mà chúng tôi triển khai mặt nạ đối tượng thu được ban đầu, bằng cách phân ngưỡng độ sáng pixel trên một hình ảnh đã được làm phẳng, đã âm thầm loại bỏ hầu hết vùng đối tượng thực sự cho ba lớp màu tối nhất (Mục 6. 4). Giải pháp khắc phục, sử dụng trực tiếp đầu ra

alpha gốc của mô hình phân đoạn thay vì tạo lại mặt nạ từ màu sắc, không tốn chi phí tính toán và luôn có sẵn; sai sót nằm ở chỗ không nhận thấy rằng hai biểu diễn của "mặt nạ đối tượng" có thể trùng khớp chặt chẽ trên một số hình ảnh nhưng lại

khác biệt rõ rệt trên những hình ảnh khác, tùy thuộc vào một thuộc tính (màu sắc đối tượng) không liên quan gì đến khuyết điểm đang được phát hiện.

7.3. Lựa chọn giữa mô hình không huấn luyện và mô hình có huấn luyện

Ranh giới giữa các phương pháp không cần huấn luyện và các phương pháp có thể huấn luyện, ít nhất là trong trường hợp của tôi, được xác định bởi quy mô dữ liệu chứ không phải kiến trúc. Về nguyên tắc, việc huấn luyện lỗi tổng hợp của SuperSimpleNet tạo ra đầu ra phân đoạn được huấn luyện trực tiếp, giúp định vị chính xác hơn so với bản đồ khoảng cách lân cận gần nhất. Sau ba vòng tái triển khai ngày càng trung thực hơn so với kiến trúc tham chiếu, nó không hội tụ trên bất kỳ lớp nào trong hai mẫu sản phẩm mà tôi đã thử nghiệm (Phụ lục A). Tôi không thể loại trừ khả năng còn tồn tại một lỗ hổng triển khai chưa được xác định, nhưng tôi đã xác minh mọi chi tiết kiến trúc mà tôi có thể tìm thấy trong triển khai tham chiếu, và lời giải thích hợp lý nhất còn lại là 80

hình ảnh huấn luyện mỗi lớp đơn giản là thấp hơn quy mô dữ liệu mà phương pháp được thiết kế và xác thực. Điều này phù hợp với mô hình rộng hơn trong báo cáo này, các phương pháp và lựa chọn tiền xử lý được thiết lập tốt ở quy mô dữ liệu chuẩn không tự động chuyển sang quy mô triển khai thực tế nhỏ hơn nhiều, và khoảng trống này cần được kiểm tra chứ không phải giả định.

7.4. Khả năng ứng dụng và giới hạn

Kết quả cho thấy quy trình phù hợp cho bước sàng lọc hoặc hỗ trợ người kiểm tra trong môi trường sản xuất có ít ảnh lỗi. Tuy nhiên, AUROC cao không đồng nghĩa vùng lỗi được phân đoạn chính xác. Khi triển khai thực tế cần tách hai ngưỡng: ngưỡng cảnh báo cấp ảnh và ngưỡng hiển thị vùng lỗi; đồng thời lưu lại ảnh mới để giám sát sự thay đổi của điều kiện chiếu sáng, phong nền và thiết kế sản phẩm.

Các giới hạn chính gồm quy mô dữ liệu nhỏ, không có mặt nạ lỗi do chuyên gia xây dựng, chưa đo độ đồng thuận giữa người chú thích, chưa đánh giá tốc độ suy luận trên đây chuyên và chưa thực hiện kiểm thử theo thời gian. Tập tham chiếu 192 ảnh có chủ ý được chú thích thô nên các giá trị IoU và độ phủ chỉ nên được hiểu như giới hạn dưới. Việc mở rộng kết luận sang sản phẩm mới cần thêm thí nghiệm độc lập.

CHƯƠNG 8. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

8.1. Kết luận

Tôi đã xây dựng và đánh giá một quy trình phát hiện và định vị bất thường một mẫu sản phẩm cho một tập dữ liệu công nghiệp thực tế gồm 12 mẫu sản phẩm với ngân sách huấn luyện cực kỳ hạn chế chỉ dành cho ảnh bình thường, 100 ảnh bình thường cho mỗi mẫu sản phẩm và không có nhãn hoặc mặt nạ lỗi ở bất kỳ giai đoạn nào. Bộ phát hiện dựa trên bộ nhớ không cần huấn luyện, PatchCore, kết hợp với một tập hợp nhỏ các quyết định tiền xử lý và hậu xử lý được tổ chức xung quanh khung chín giai đoạn (OC-MAR) do thầy hướng dẫn của tôi đề xuất, đã đạt được AUROC trung bình ở cấp độ ảnh là 0,996 trên 12 lớp, ổn định trong phạm vi 0,002 trên 5 hạt giống ngẫu nhiên (Mục 6.6), và rõ ràng vượt trội so với đường cơ sở thống kê cổ điển (0,898).

Theo quan điểm của tôi, đóng góp bền vững hơn của công trình này không phải là con số thống kê nổi bật mà là ba điều tôi phát hiện ra trong quá trình cố gắng xác minh nó. Mặt nạ đối tượng được tạo ra từ hình ảnh đã loại bỏ nền bằng cách phân ngưỡng màu sắc thường thất bại một cách đáng kể đối với các đối tượng có màu tối, một mô hình chỉ trở nên rõ ràng khi tôi kiểm tra định lượng trên tất cả 12 mẫu sản phẩm thay vì chỉ tin tưởng vào hai ví dụ mà chúng tôi đã kiểm tra ban đầu (Mục 6.4); một giải pháp thay thế có thể huấn luyện, có lỗi tổng hợp (SuperSimpleNet) về nguyên tắc cung cấp khả năng định vị trực tiếp hơn đã không hội tụ ở quy mô dữ liệu này mặc dù đã trải qua ba vòng xác minh kiến trúc so với triển khai tham chiếu, một kết quả tiêu cực.

kỳ hướng nào, vì không phải mọi cải tiến khả thi đều hữu ích.

8.2. Hướng phát triển

Trong nghiên cứu này, chất lượng định vị chủ yếu được đánh giá định tính, vì tập dữ liệu không cung cấp mặt nạ khuyết tật được vẽ bởi chuyên gia; Mục 6.10 báo cáo một phần kiểm tra định lượng so với một tập con được chú thích thủ công,

cổ ý thô (192 hình ảnh trên tất cả 12 mẫu sản phẩm), cho thấy độ chồng chéo ranh giới (IoU) thấp nhưng độ chính xác trò chơi chỉ điểm cao (0, 875), phù hợp với một mô hình xác định đáng tin cậy vị trí khuyết tật tổng quát chính xác mà không cần vạch rõ ranh giới của nó. Thu hẹp khoảng cách này hơn nữa, với dữ liệu tham chiếu chặt chẽ hơn, sự đồng thuận giữa những người chú thích được đo lường, hoặc một đường cong PRO đa ngưỡng đầy đủ, là hướng đi có giá trị nhất còn lại cho công việc trong tương lai, trước khi tinh chỉnh kiến trúc của chính bộ dò.

- Xây dựng bộ mặt nạ lỗi do nhiều chuyên gia chú thích và đo mức độ đồng thuận giữa người chú thích.
- Đánh giá PRO đa ngưỡng, đường cong precision-recall và chi phí lỗi theo yêu cầu kiểm soát chất lượng.
- Thử nghiệm mô hình trên dữ liệu thu thập theo thời gian để phát hiện trôi dữ liệu và thay đổi điều kiện chụp.
- Tối ưu hóa ngân hàng bộ nhớ, thời gian suy luận và cơ chế cập nhật đối với mã sản phẩm mới.
- Thiết kế giao diện xác nhận cảnh báo để phản hồi của nhân viên kiểm tra trở thành dữ liệu hiệu chuẩn có kiểm soát.

TÀI LIỆU THAM KHẢO

- [1] P. Bergmann, M. Fauser, D. Sattlegger và C. Steger, 'MVTec AD - A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection, ' Proc. IEEE/CVF CVPR, pp. 9584-9592, 2019.
- [2] F. T. Liu, K. M. Ting và Z. -H. Zhou, 'Isolation Forest, ' Proc. IEEE International Conference on Data Mining, 2008.
- [3] B. Rolih, M. Fučka và D. Skočaj, 'SuperSimpleNet: Unifying Unsupervised and Supervised Learning for Fast and Reliable Surface Defect Detection, ' arXiv: 2408. 03143, 2024.
- [4] K. Roth, L. Pemula, J. Zepeda, B. Schölkopf, T. Brox và P. Gehler, 'Towards Total Recall in Industrial Anomaly Detection, ' Proc. IEEE/CVF CVPR, 2022.
- [5] V. Zavrtanik, M. Kristan và D. Skočaj, 'DRAEM - A Discriminatively Trained Reconstruction Embedding for Surface Anomaly Detection, ' Proc. IEEE/CVF ICCV, pp. 8330-8339, 2021.
- [6] J. Zhang, S. A. Bargal, Z. Lin, J. Brandt, X. Shen và S. Sclaroff, 'Top-Down Neural Attention by Excitation Backprop, ' International Journal of Computer Vision, vol. 126, no. 10, pp. 1084-1102, 2018.

PHỤ LỤC A. THỬ NGHIỆM SUPERSIMPLENET

A.1. Thiết lập

Như một giải pháp thay thế cho việc định vị không cần huấn luyện của PatchCore, chúng tôi đã thử huấn luyện SuperSimpleNet [3] ở cấu hình không giám sát trên hai lớp có AUROC cơ sở thấp nhất của PatchCore, FA-1047 và FA-808. Không giống như PatchCore, SuperSimpleNet huấn luyện bộ điều chỉnh tính năng nhẹ và đầu phân đoạn/phân loại từ đầu đến cuối thông qua phương pháp giảm độ dốc, sử dụng các khiếm khuyết giả được tổng hợp bằng cách chèn các nhiễu loạn Gaussian được che bằng nhiễu Perlin vào không gian tính năng của xương sống (đã đóng băng), không yêu cầu hình ảnh bị lỗi thực sự hoặc chú thích thủ công ở bất kỳ thời điểm nào.

A. 1 Triển khai Cấu trúc xương sống (WideResNet-50, lớp 2 + lớp 3) phản ánh cấu hình của PatchCore nhưng được mở rộng lên lưới đặc trưng 64×64 (so với 28×28 của PatchCore), theo kiến trúc đã được công bố. Quá trình huấn luyện sử dụng 80 hình ảnh bình thường cho mỗi lớp (cùng cách phân chia huấn luyện như PatchCore), 300 epoch và các siêu tham số phù hợp với bài báo gốc ở những chỗ có thể áp dụng.

A.2. Hiệu chỉnh theo triển khai tham chiếu

Một triển khai ban đầu, chỉ dựa trên việc đọc bài báo đã xuất bản, đã cho kết quả rất kém (AUROC 0.436 trên FA-1047, 0.037 trên FA-808, tức là tệ hơn cả ngẫu nhiên) với tổn thất huấn luyện không giảm trong hơn 300 epoch. So sánh trực tiếp với triển khai tham chiếu của các tác giả¹ cho thấy rằng thuật ngữ tổn thất phân đoạn của chúng tôi đã được triển khai không chính xác, tôi đã triển khai nó như một khoảng cách L1 được giới hạn giữa các dự đoán được kích hoạt bằng sigmoid và các mục tiêu nhị phân, trong khi triển khai tham chiếu sử dụng tổn thất biên độ bản lề trực tiếp trên logit thô (đẩy logit vùng bình thường xuống dưới -0.5 và logit vùng


khuyết tật lên trên +0. 5). Việc sửa chữa thuật ngữ tổn thất này đã cải thiện kết quả trên một lớp (FA-808, AUROC 0. 915) nhưng về cơ bản không thay đổi trên

luyện) mà tôi đã bỏ qua ban đầu. Sau khi sửa tất cả những điểm không nhất quán này để phù hợp với triển khai tham chiếu, một lần chạy huấn luyện lại hoàn chỉnh trên tập dữ liệu huấn luyện thực gồm 80 hình ảnh (thay vì một tập con nhỏ để gỡ lỗi) vẫn không hội tụ, tổn thất huấn luyện dao động giữa khoảng 1, 05 và 1, 11 trong suốt 300 epoch cho cả hai mẫu sản phẩm, và AUROC cuối cùng vẫn kém và không nhất quán giữa các lớp (FA-1047, 0, 384; FA-808, 0, 891). định tính, giảm mạnh từ khi khởi tạo trong khoảng 20 epoch đầu tiên, sau đó là một giai đoạn ổn định kéo dài mà không có sự cải thiện nào nữa, không bị ảnh hưởng bởi sự suy giảm tốc độ học theo lịch trình.

A.3. Phân tích kết quả không hội tụ

Qua ba lần chạy huấn luyện độc lập với các triển khai được sửa lỗi dần dần, tất cả các lần chạy đều thể hiện cùng một chế độ lỗi định tính: tổn thất huấn luyện chững lại ngay sau khi khởi tạo và không giảm đáng kể. Kết quả tốt đôi khi đạt được trên FA-808 mặc dù đường cong tổn thất phẳng, theo tôi, phù hợp hơn với sự tương quan ngẫu nhiên từ việc khởi tạo trọng số ngẫu nhiên hơn là với quá trình học thực sự, vì một mô hình hội tụ được kỳ vọng sẽ cải thiện nhất quán trên các lớp hơn là phân kỳ mạnh giữa hai mẫu sản phẩm được huấn luyện theo cùng một quỹ đạo tổn thất không đổi. Tôi không thể loại trừ một điểm khác biệt còn lại so với triển khai tham chiếu, đó là cơ chế sao chép lô trong quá trình tiêm lỗi giả mà tôi không tái tạo được, và không thể loại trừ khả năng tập huấn luyện

trên mỗi mẫu sản phẩm (80 hình ảnh bình thường) quá nhỏ so với 200-300 hình ảnh mỗi loại được sử dụng trong các bài kiểm tra chuẩn của bài báo cáo gốc (MVTec AD, VisA) để kiến trúc này có thể hội tụ một cách đáng tin cậy. Tôi báo cáo kết quả tiêu cực này như một điều kiện biên hơn là một hạn chế của nỗ lực kỹ thuật của tôi, vì cấu hình cuối cùng phù hợp với kiến trúc đã được công bố theo như sự xác minh tốt nhất của tôi.



Hình A.1. Hàm mất mát huấn luyện SuperSimpleNet trên FA-1047 và FA-808.